Predviđanje uspjeha bankarskog marketinga Projektni prijedlog za kolegij Strojno učenje

Davorin Gradečak, Petra Jambriško, Jakov Krunić

21. travnja 2020.

Opis problema

Predviđanje uspjeha bankarskog marketinga na temelju popisnih podataka:

- train podaci 41188 instanci/ispitanih korisnika
- test podaci 4119 instanci/ispitanih korisnika

Svaki korisnik je opisan s 20 atributa i atributom y koji predviđamo (target).

Atribut y nam govori je li korisnik ugovorio oročeni depozit ili ne - y je kategorijska varijabla.

Predviđanje uspjeha bankarskog marketinga

Davorin Gradečak, Petra Jambriško, Jakov Krunić

Opis i cilj problema

Analiza podataka

Metode, algoritmi i ocjene njihove uspješnosti

Cilj projekta

- odrediti utjecaj pojedinih atributa na y (target)
- napraviti što uspješniji klasifikator, tj. model koji što uspješnije predviđa hoće li korisnik ugovoriti oročeni depozit

Hipoteza: Moguće je primjenom adekvatnih algoritama strojnog učenja dobiti model koji uspješno predviđa odluku korisnika. Predviđanje uspjeha bankarskog marketinga

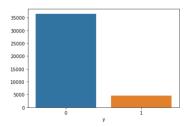
Davorin Gradečak, Petra Jambriško, Jakov Krunić

Opis i cilj problema

Analiza podataka

Metode, algoritmi i ocjene njihove uspješnosti

Analiza podataka



U train podacima, od svih korisnika, njih 36548 nije ugovorilo oročeni depozit, a njih 4640 jest. Negativnih slučajeva je skoro 8 puta više od pozitivnih.

Predviđanje uspjeha bankarskog marketinga

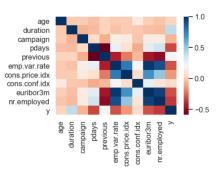
Davorin Gradečak, Petra Jambriško, Jakov Krunić

Opis i ciij probleti

Analiza podataka

Metode, algoritmi i ocjene njihove uspješnosti

Analiza podataka



Korelacijska matrica atributa pokazuje da je target varijabla y najviše korelirana s trajanjem poziva. Predviđanje uspjeha bankarskog marketinga

Davorin Gradečak, Petra Jambriško, Jakov Krunić

opis i dig problem

Analiza podataka

Metode, algoritmi i ocjene njihove uspješnosti

Metode, algoritmi, tehnike i alati

Algoritmi koje ćemo koristiti:

- logistička regresija
- naivni Bayes
- k-najbližih susjeda
- slučajne šume
- metoda potpornih vektora
- neuronske mreže

Metode za poboljšanja i uspoređivanja uspješnosti:

- preuređivanje podataka
- korištenje PCA (Analiza glavnih komponenata)
- način rješavanja problema nedostajućih vrijednosti

Predviđanje uspjeha bankarskog marketinga

Davorin Gradečak, Petra Jambriško, Jakov Krunić

Opis i cilj problema

Analiza podataka

Metode, algoritmi i ocjene njihove uspješnosti

predloženog projekta

Ocjene uspješnosti metoda i algoritama

- Evaluacija pomoću vrijednosti AUC (Area Under Curve), tj. površine ispod ROC (Receiver Operating Characteristic) krivulje
- ► Matrica konfuzije
- Vrijednost preciznosti P i F₁, tj. mjera koja povezuje preciznost i osjetljivost

Predviđanje uspjeha bankarskog marketinga

Davorin Gradečak, Petra Jambriško, Jakov Krunić

31

Analiza podataka

Metode, algoritmi i ocjene njihove uspješnosti

Očekivani rezultati predloženog projekta

Kao konačni rezultat projekta očekujemo model koji što uspješnije rješava dani klasifikacijski problem.

Predviđanje uspjeha bankarskog marketinga

Davorin Gradečak, Petra Jambriško, Jakov Krunić

- |----

Analiza podataka

Metode, algoritmi i ocjene njihove uspješnosti